G.I. Go

Générateurs & Itérateurs en Go

Comment compter les Gophers sans perdre la mémoire

Image de ChatGPT

Benoît Masson

OVHcloud

19 novembre 2024

Générique

- Développeur Go depuis 2015
- Software Craftsman

@OVHcloud Rennes
Noms de Domaines depuis 2020

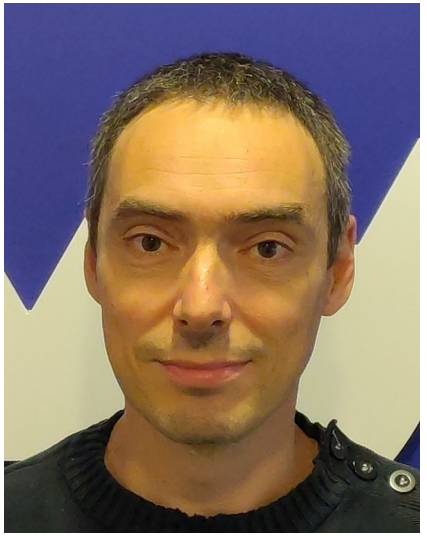

benoitmasson

Mais pourquoi ?

- Uniformisation des pratiques observées
  - archive/tar.Reader.Next
  - bufio.Reader.ReadByte
  - bufio.Scanner.Scan
  - container/ring.Ring.Do
  - database/sql.Rows
  - expvar.Do
  - flag.Visit
  - go/token.FileSet.Iterate
  - path/filepath.Walk
  - runtime.Frames.Next
  - sync.Map.Range
  - …

Mais pourquoi ?

- Uniformisation des pratiques observées
  - archive/tar.Reade…Ne… …ag.Visit
  - bufio.Reader.Rea…By… …go/token.FileSet.Iterate
  - bufio.Scanner.Sca… …th/filepath.Walk
  - container/ring.Ring.… …untime.Frames.Next
  - database/sql.Ro… …c.Map.Range
  - expvar.Do …

- S'appuie sur les génériques, disponibles depuis 2022 (Go 1.18)

Historique

- Discuté depuis octobre 2022
- Expérimenté depuis février 2024 (Go 1.22)
- Généralisé en août 2024 (Go 1.23)

Image de macrovector_official sur Freepik

Comment ça marche

Comment ça marche

- itérateur « push » = **générateur**
  - 1 ou 2 valeurs
- `yield`, `break`
- **itérateur** « pull »
- test unitaire

Bibliothèque standard

slices

- All([]E) iter.Seq2[int, E]
- Values([]E) iter.Seq[E]
- Collect(iter.Seq[E]) []E
- AppendSeq([]E, iter.Seq[E]) []E
- Backward([]E) iter.Seq2[int, E]
- Sorted(iter.Seq[E]) []E
- SortedFunc(iter.Seq[E], func(E, E) int) []E
- SortedStableFunc(iter.Seq[E], func(E, E) int) []E
- Repeat([]E, int) []E
- Chunk([]E, int) iter.Seq([]E)

maps

- All(map[K]V) iter.Seq2[K, V]
- Keys(map[K]V) iter.Seq[K]
- Values(map[K]V) iter.Seq[V]
- Collect(iter.Seq2[K, V]) map[K, V]
- Insert(map[K, V], iter.Seq2[K, V])

Critiques

Lire par exemple : `go-evolves-in-the-wrong-direction`

- Deux façons d'itérer sur les anciennes bibliothèques
- Signature de l'itérateur restrictif, pas adapté à toutes les situations
- Augmentation de la complexité implicite du *`range`*
- Vérification manuelle des erreurs à chaque itération

Critiques

Lire par exemple : `go-evolves-in-the-wrong-direction`

- Deux façons d'itérer sur les anciennes bibliothèques
- Signature de l'itérateur restrictif, pas adapté à toutes les situations
- Augmentation de la complexité implicite du *`range`*
- Vérification manuelle des erreurs à chaque itération

Mon avis : pas un vrai problème, la complexité étant déportée dans une fonction isolée, l'usage est **simple** et **clair**

Cas d'usage

OVHcloud

Image de brgfx sur Freepik

Parcourir un fichier mot à mot

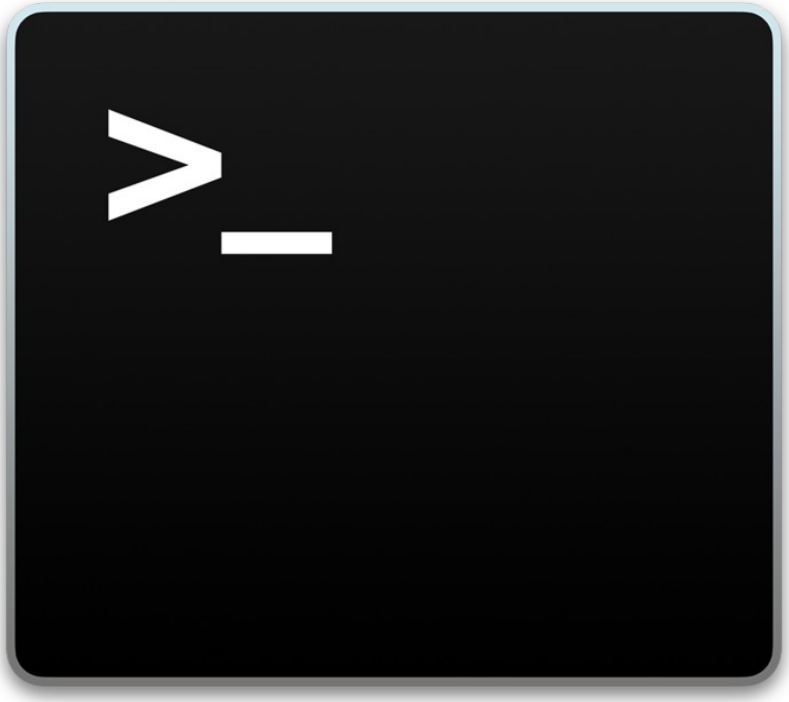

Parcourir un fichier mot à mot

- performance (rapidité, mémoire)
- lisibilité

Requêtes paginées

```
func Words(client api.Client) iter.Seq2[string, error] {
    return func(yield func(string, error) bool) {
      byteBuf := make([]byte, bufSize)  var cursor  string
      wordBuf := bytes.Buffer{}         var results []string
        for {
            n, err := r.Read(byteBuf)     results, cursor, err := client.getPage(cursor)
            if err != nil {
                if errors.Is(err, io.EOF) {
                    return
                }
                if !yield("", fmt.Errorf("failed to get page: %w", err)) {
                  return
                }
            }

            for _, result := range results {
                b := byteBuf[i]
                if !unicode.IsSpace(rune(b)) {
                    wordBuf.WriteByte(b)
                    continue
                }
                // b is a space
                if wordBuf.Len() == 0 {
                    // ignore empty words
                    continue
                }
                if !yield(result, nil) {
                    return
                }
                wordBuf.Reset()
            }
        }
    }
}
```

Usage

```
for result, err := Words(client) {
    if err != nil {
        // ...
        break
    }
    // ...
}
```

Scan SQL

Source : `github.com/achille-roussel/sqlrange`

```
for p, err := range sqlrange.Query[Point](db, `select x, y from points`) {
    if err != nil {
        ...
    }
    ...
}
```

Comptons les gophers

Image de catalyststuff sur Freepik

Comptons les gophers (distincts)

Image de catalyststuff sur Freepik

Décompte exact

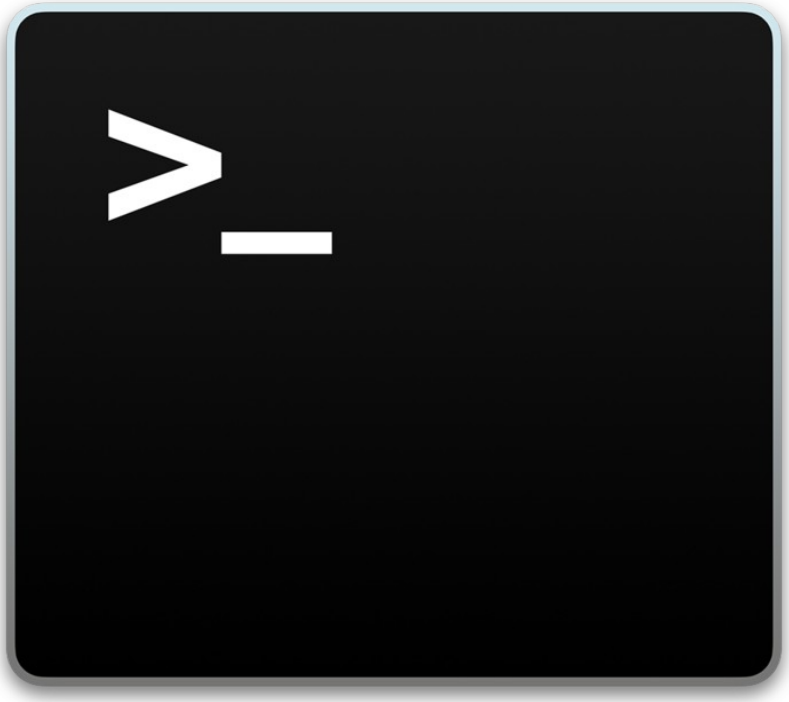

Décompte exact

- performant
- mémoire non bornée

Décompte approximatif - Algorithme

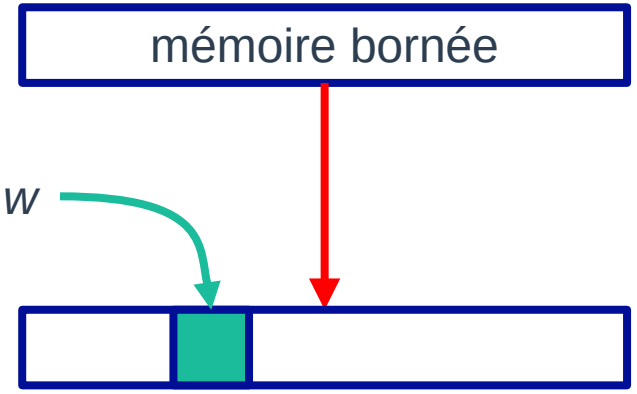

Décompte approximatif - Algorithme

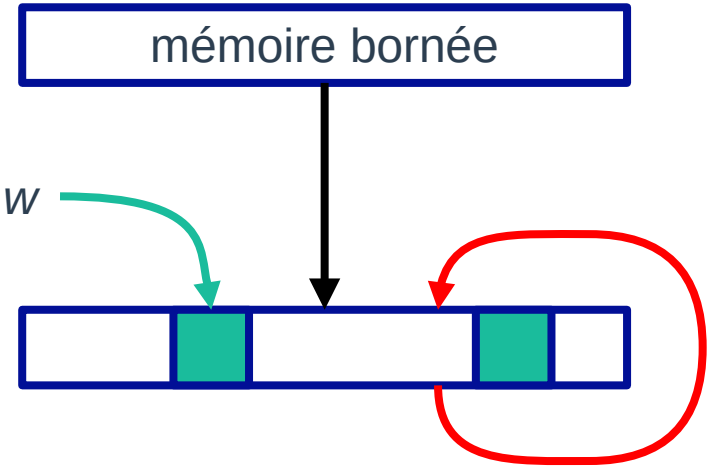

Décompte approximatif - Algorithme

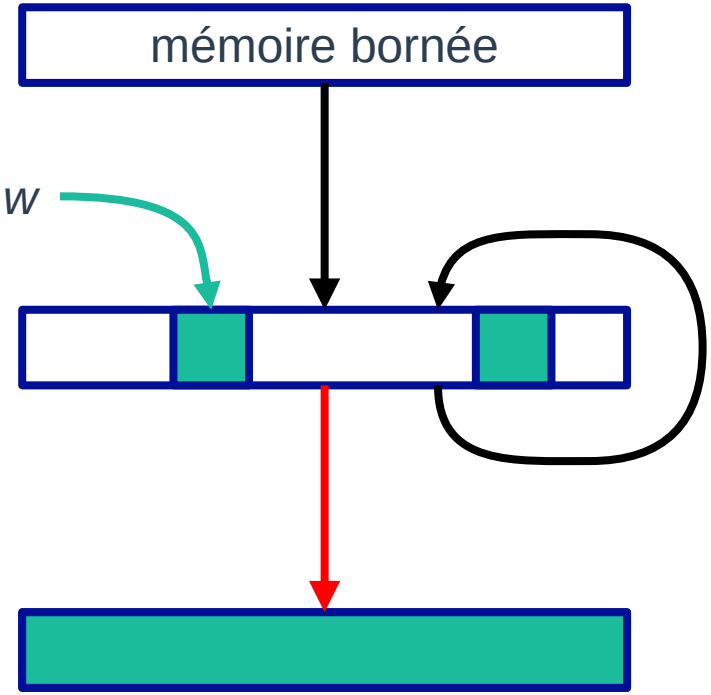

Décompte approximatif - Algorithme

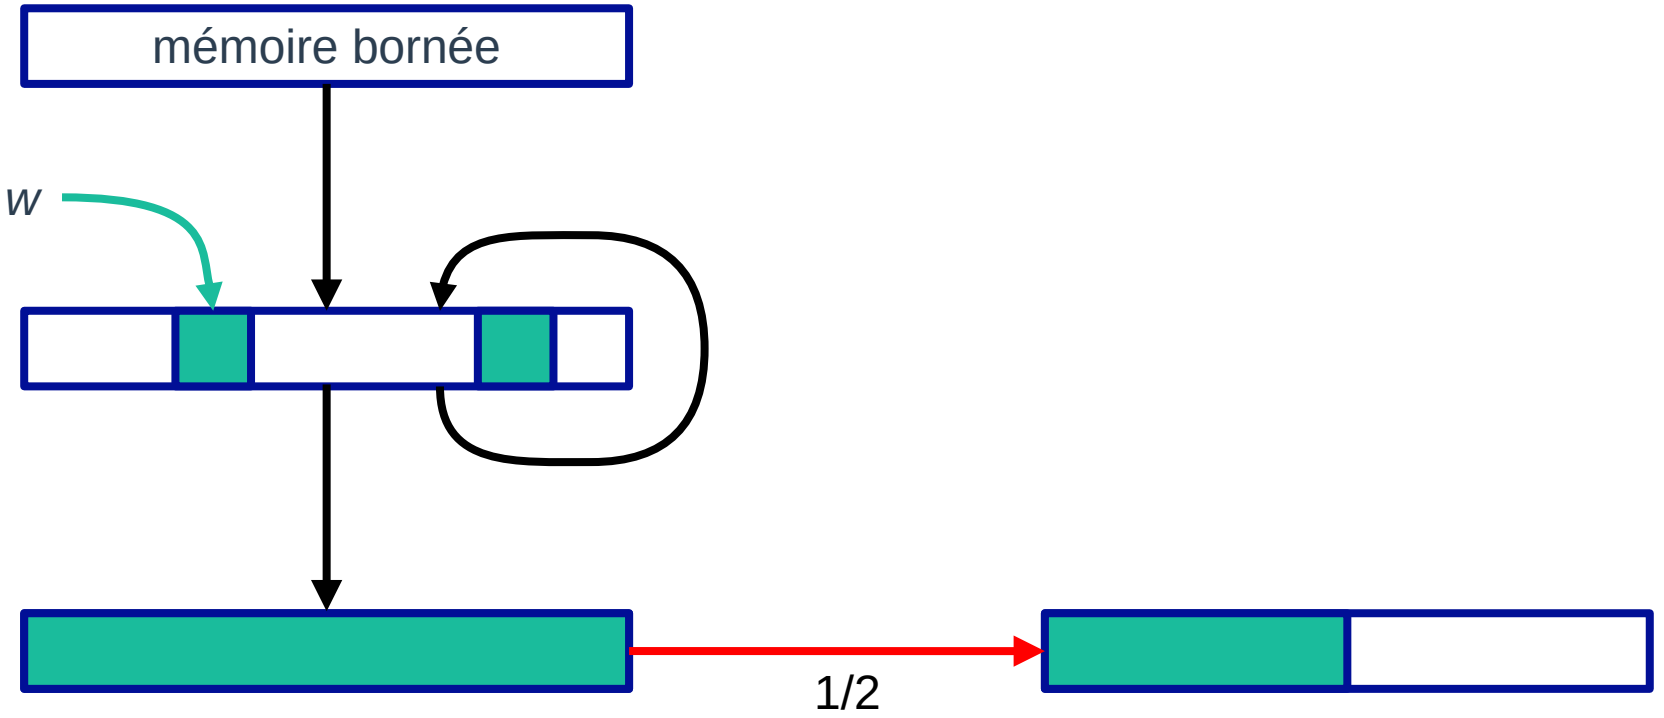

Décompte approximatif - Algorithme

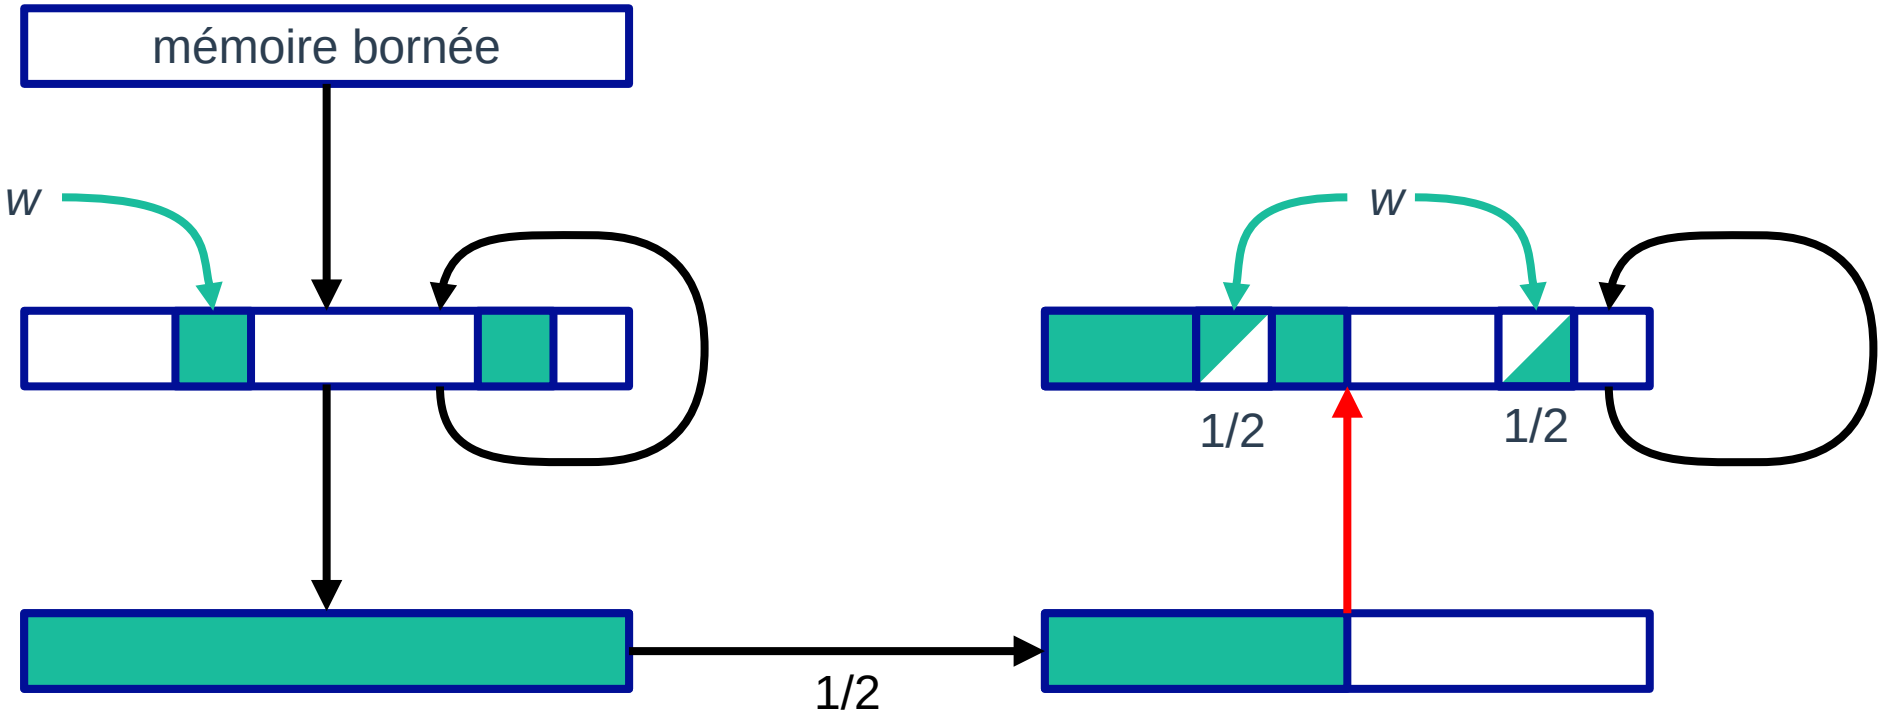

Décompte approximatif - Algorithme

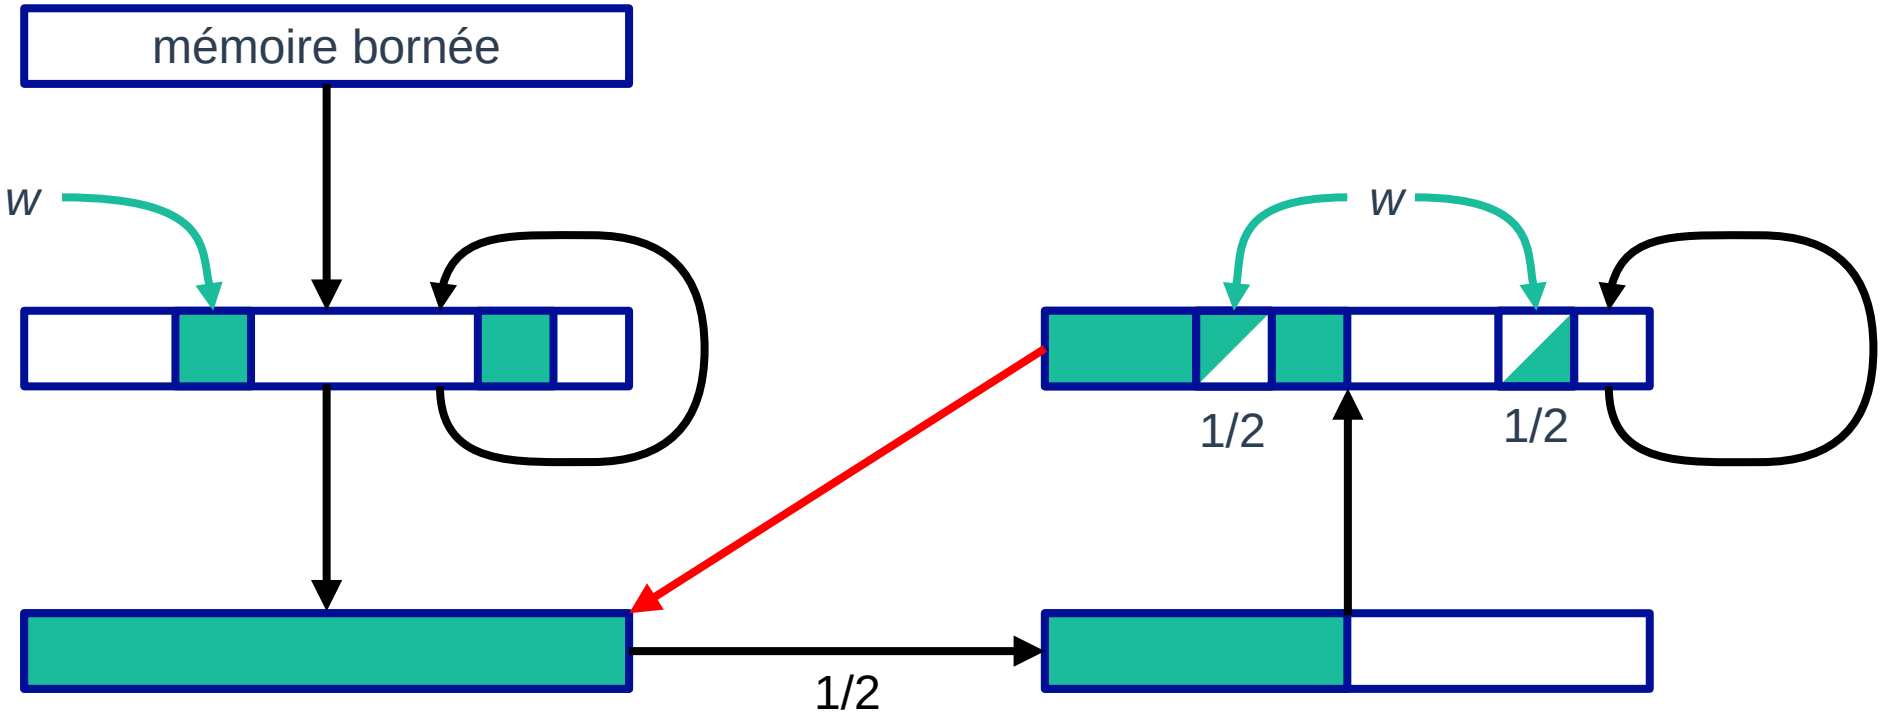

Décompte approximatif - Algorithme

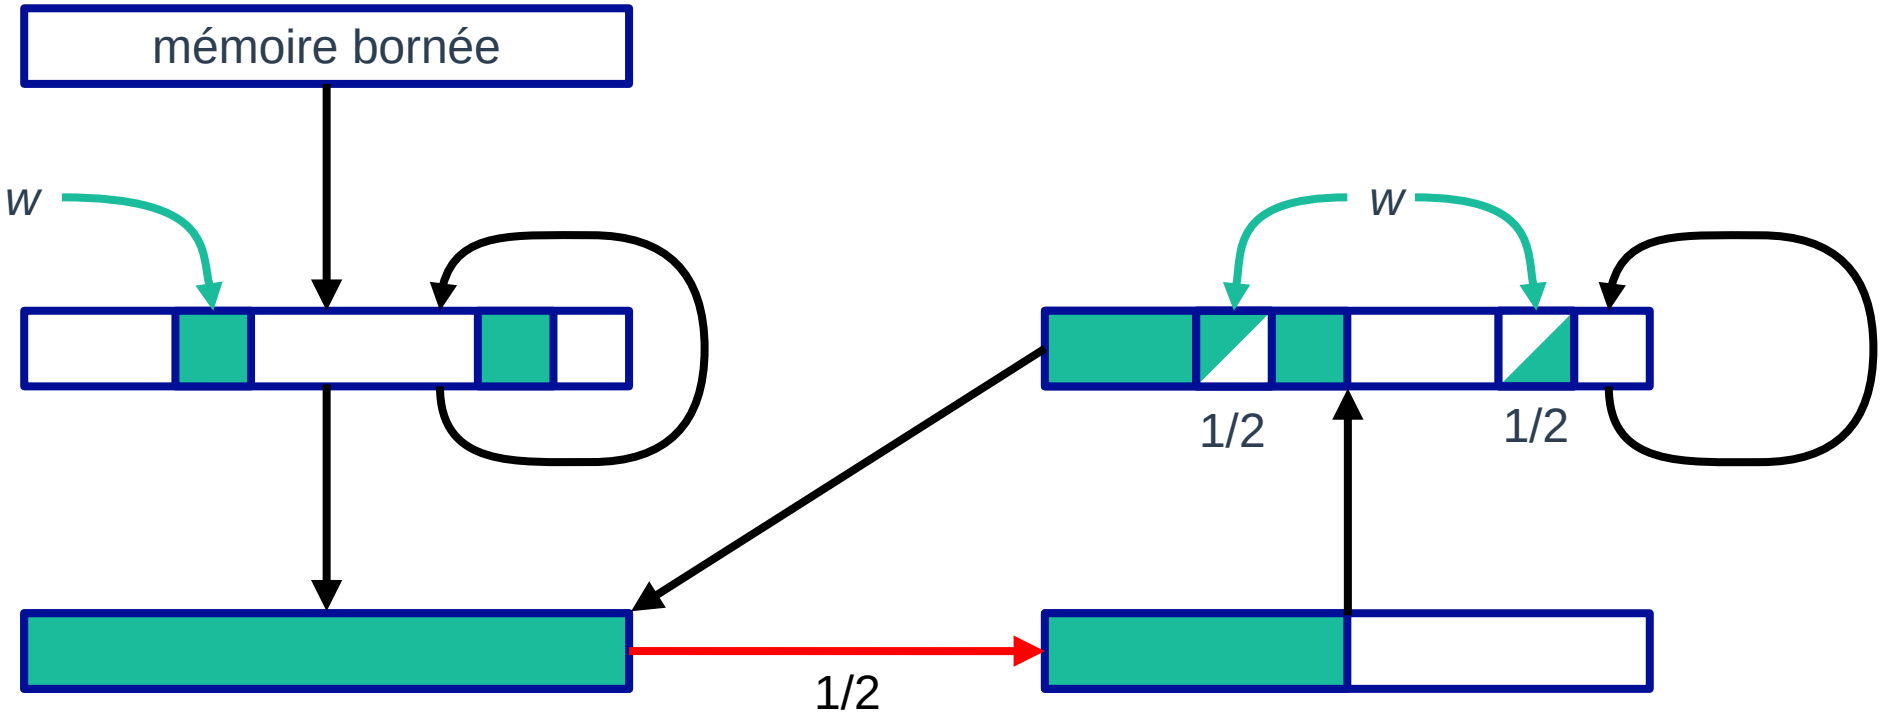

Décompte approximatif - Algorithme

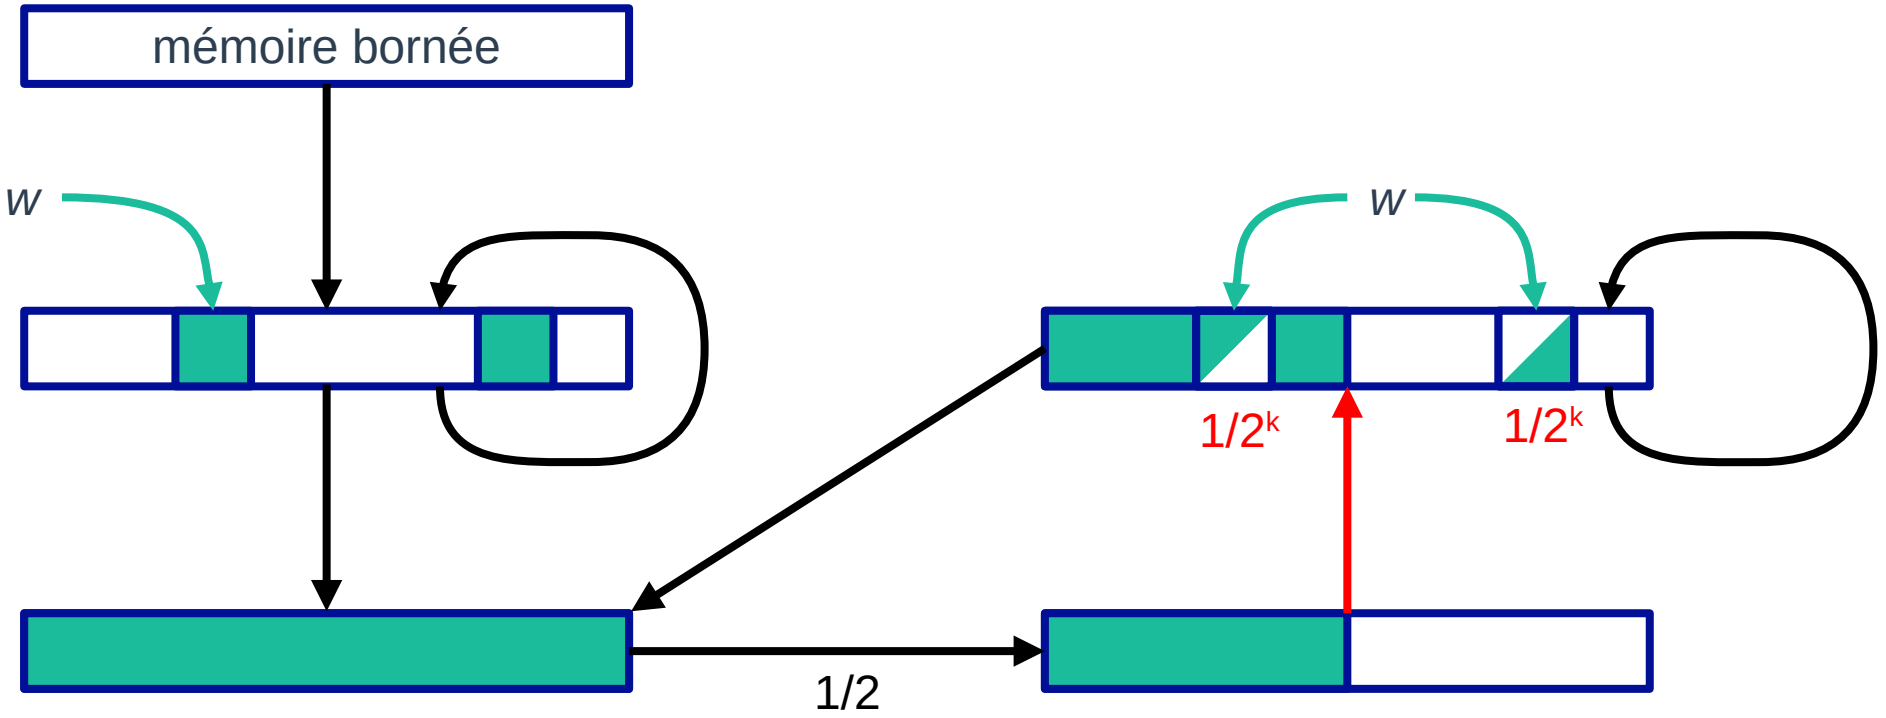

Décompte approximatif - Algorithme

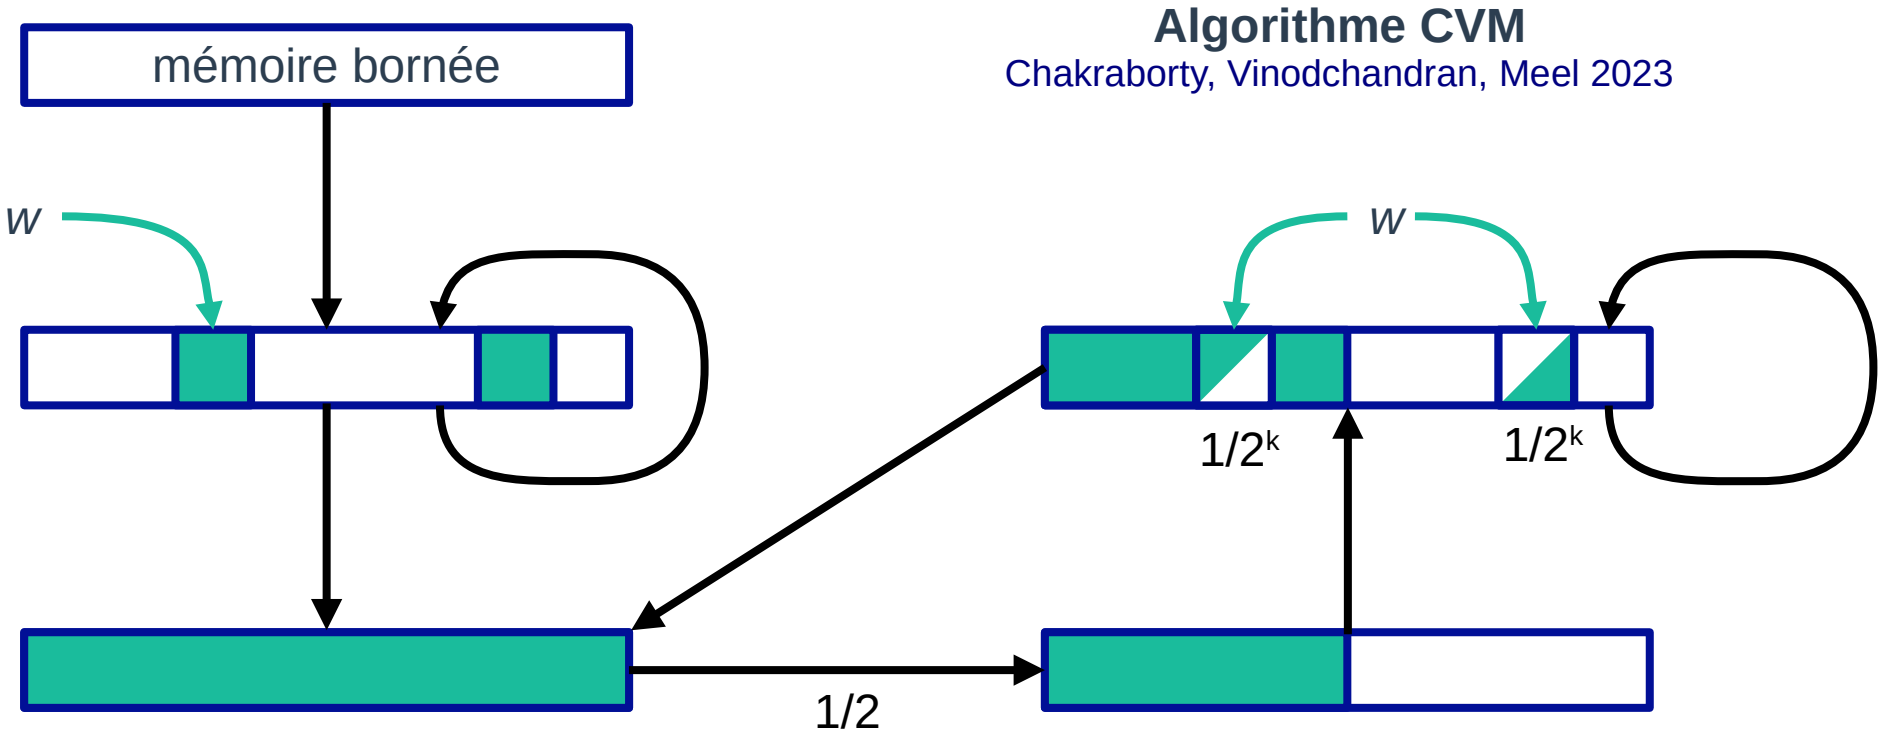

Algorithme CVM

Chakraborty, Vinodchandran, Meel 2023

Un peu de probabilités

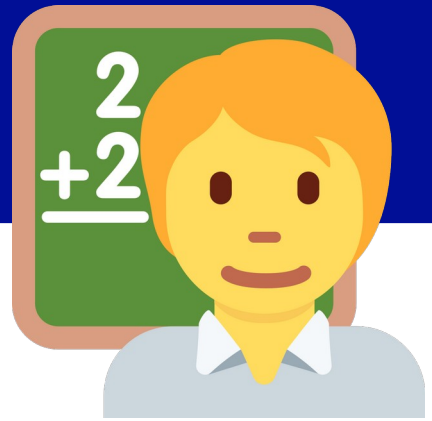

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

Un peu de probabilités

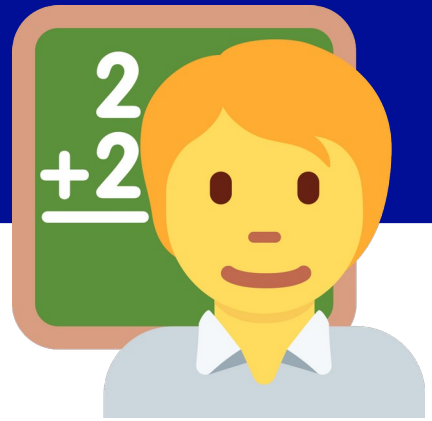

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

- si *w* n'apparaît qu'au premier round, *P(w) = 1/2* (« nettoyage »)

Un peu de probabilités

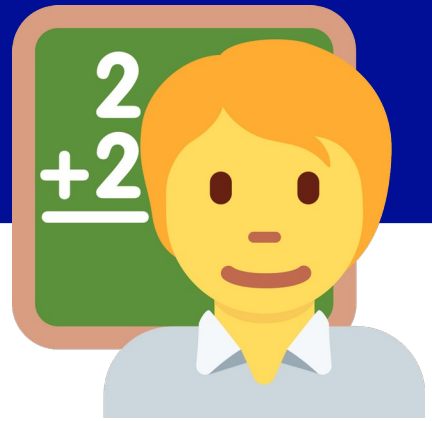

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

- si *w* n'apparaît qu'au premier round, *P(w) = 1/2* (« nettoyage »)
- si *w* n'apparaît qu'au second round, *P(w) = 1/2* (ajout)

Un peu de probabilités

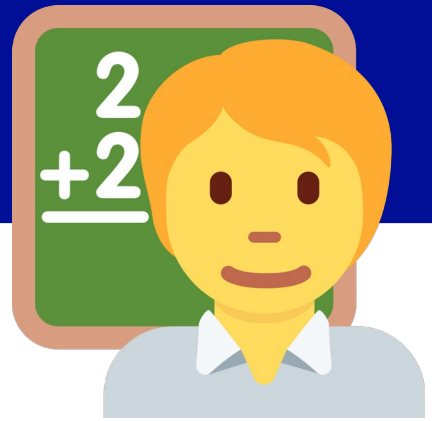

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

- si *w* n'apparaît qu'au premier round, *P(w) = 1/2* (« nettoyage »)
- si *w* n'apparaît qu'au second round, *P(w) = 1/2* (ajout)
- si *w* apparaît dans les 2 rounds, *P(w) = 1/2* (ajout/suppression)

Un peu de probabilités

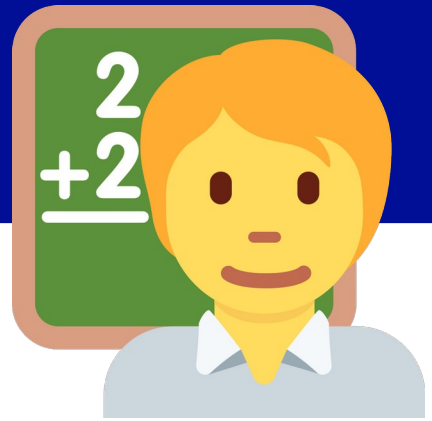

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

- si *w* n'apparaît qu'au premier round, *P(w) = 1/2* (« nettoyage »)
- si *w* n'apparaît qu'au second round, *P(w) = 1/2* (ajout)
- si *w* apparaît dans les 2 rounds, *P(w) = 1/2* (ajout/suppression)

Probabilité générique après *k* rounds (récurrence) : $\boldsymbol{P(w) = 1/2^k}$

Un peu de probabilités

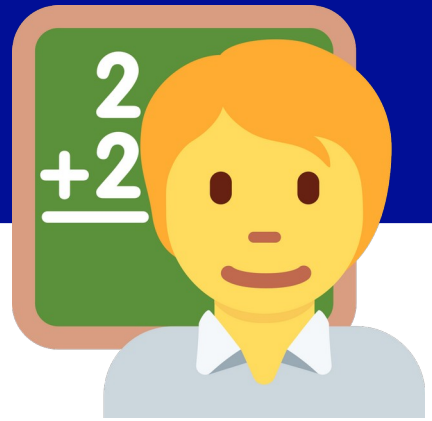

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

- si *w* n'apparaît qu'au premier round, *P(w) = 1/2* (« nettoyage »)
- si *w* n'apparaît qu'au second round, *P(w) = 1/2* (ajout)
- si *w* apparaît dans les 2 rounds, *P(w) = 1/2* (ajout/suppression)

Probabilité générique après *k* rounds (récurrence) : $\boldsymbol{P(w) = 1/2^k}$

Nombre *N* de mots distincts du texte :

$$size(mem) \simeq N * P(w)$$

Un peu de probabilités

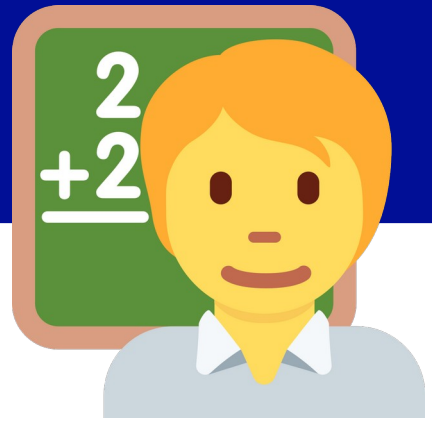

Probabilité *P(w)* qu'un mot du texte soit dans la table après **2 rounds** :

- si *w* n'apparaît qu'au premier round, *P(w) = 1/2* (« nettoyage »)
- si *w* n'apparaît qu'au second round, *P(w) = 1/2* (ajout)
- si *w* apparaît dans les 2 rounds, *P(w) = 1/2* (ajout/suppression)

Probabilité générique après *k* rounds (récurrence) : $\boldsymbol{P(w) = 1/2^k}$

Nombre *N* de mots distincts du texte :

$$size(mem) \simeq N * P(w)$$

$$N \simeq size(mem) / P(w) = \boldsymbol{size(mem) * 2^k}$$

Implémentation

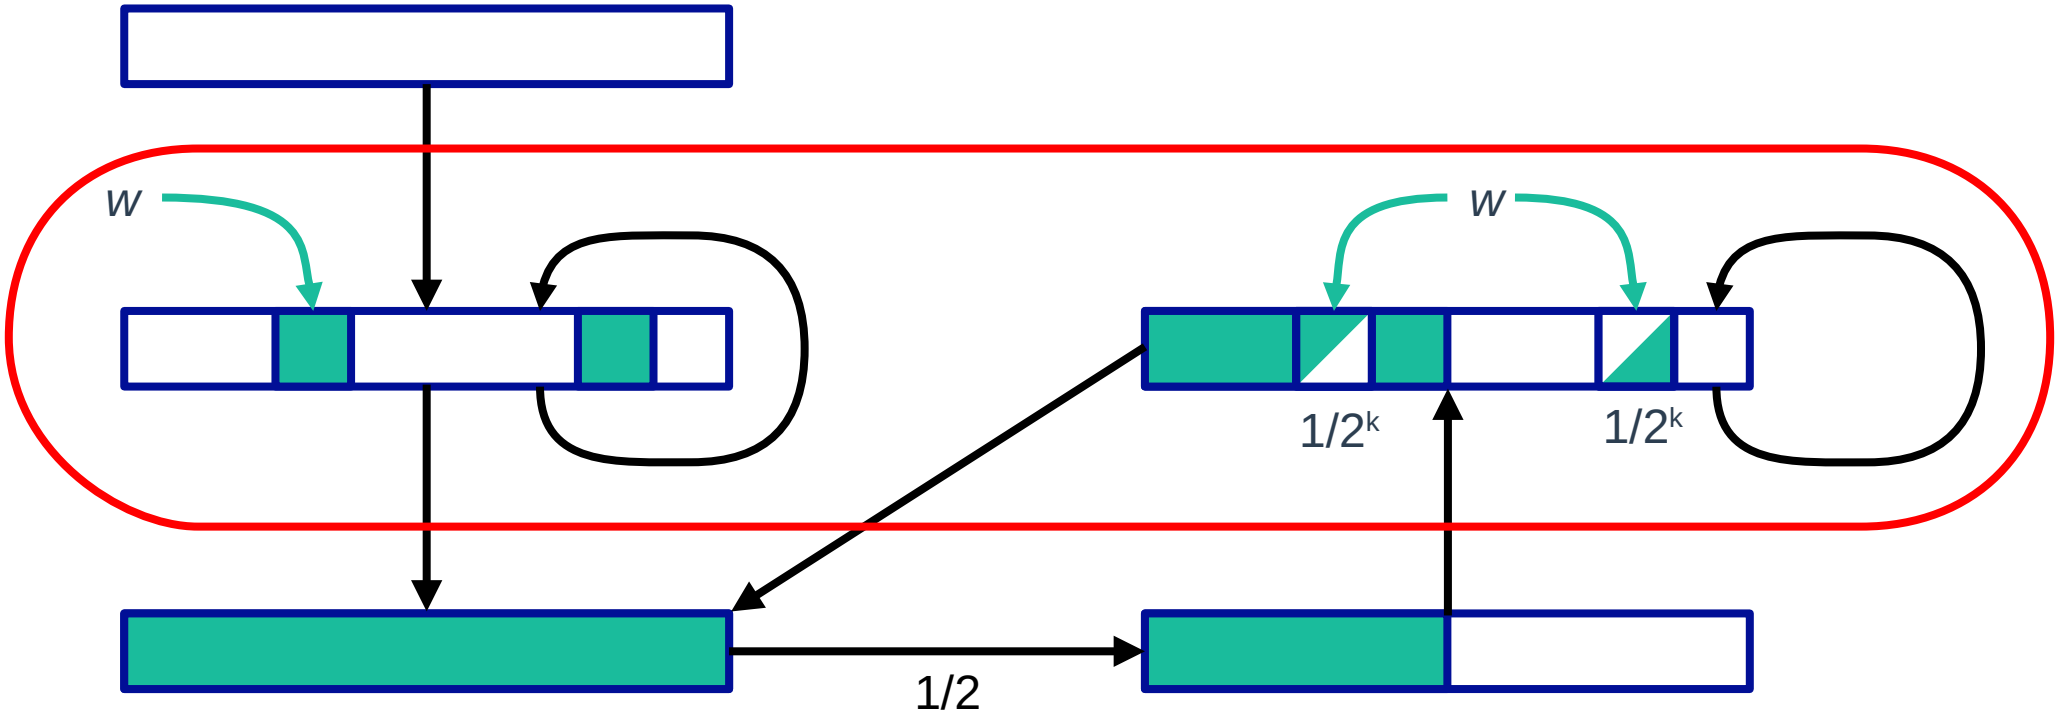

Implémentation

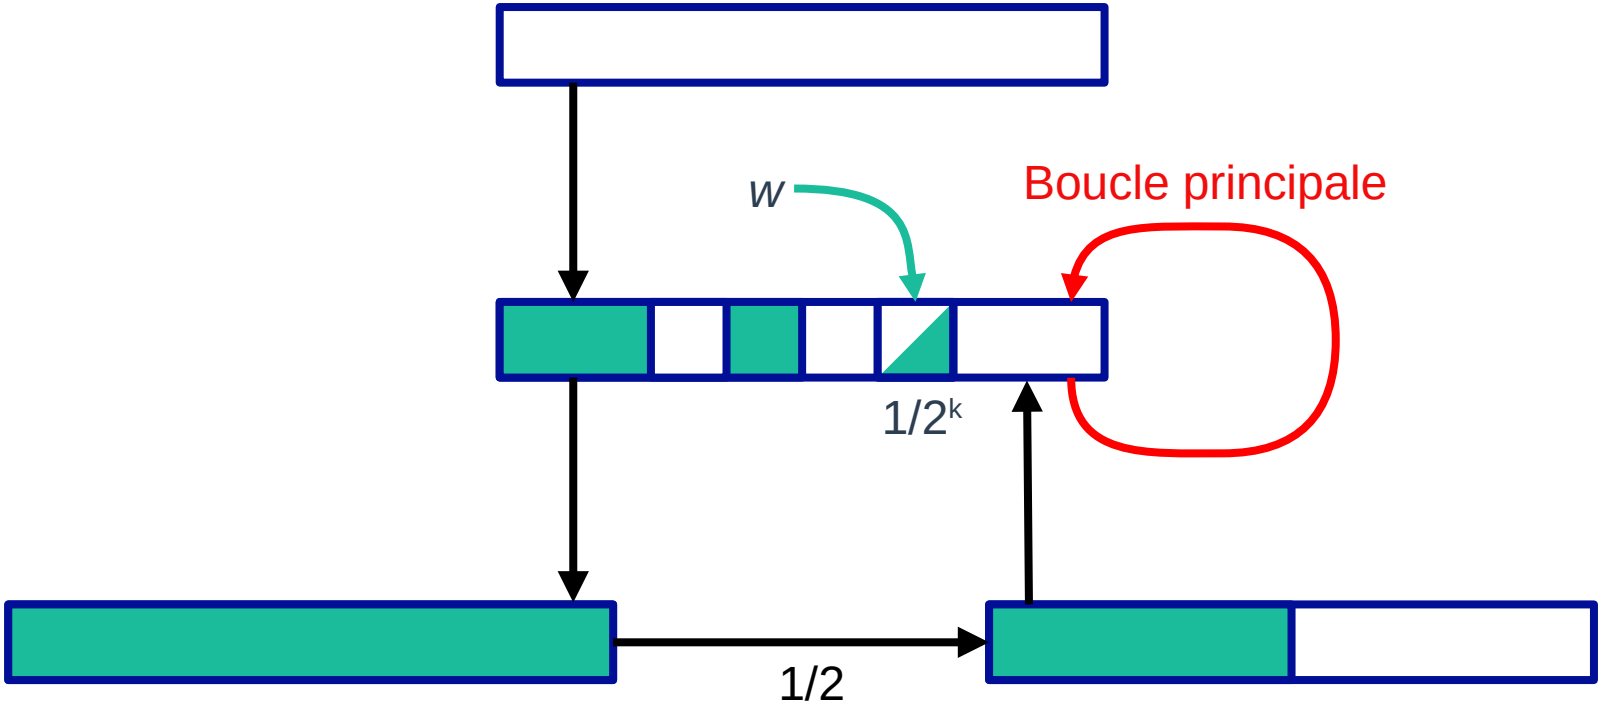

Décompte approximatif

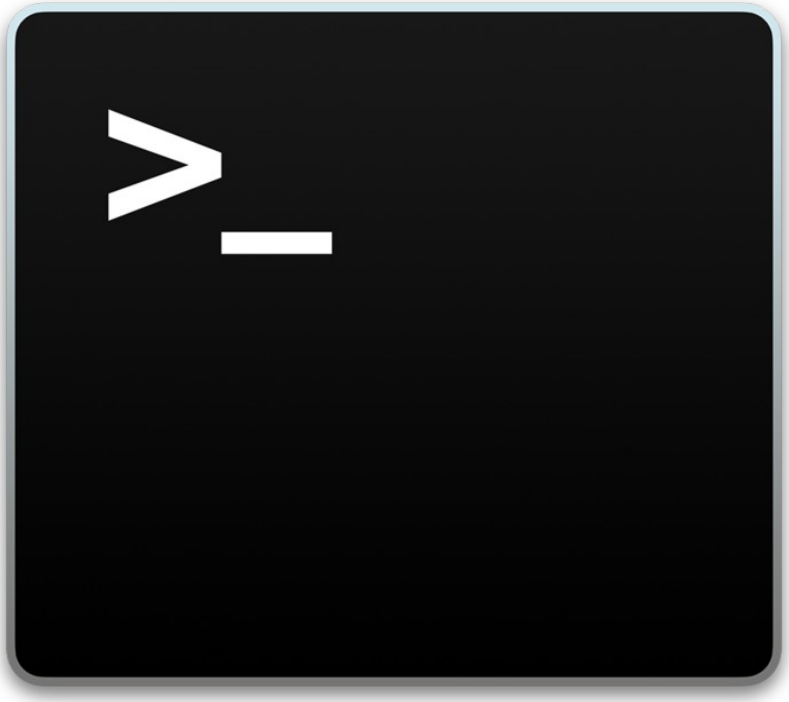

Décompte approximatif

- performant
- consommation mémoire maîtrisée
- approximation raisonnable

Conclusion

Les génériques, c'est magique
⇒ complexité technique masquée dans la bibliothèque, usage simple

On peut encore faire de l'algo en 2024
(et c'est pas forcément compliqué)

Autre nouveauté de Go 1.23 pour optimiser la mémoire : unique
⇒ article de Valentin Deleplace

Merci !

Code & Slides

https://github.com/benoitmasson/gi-go

OVHcloud

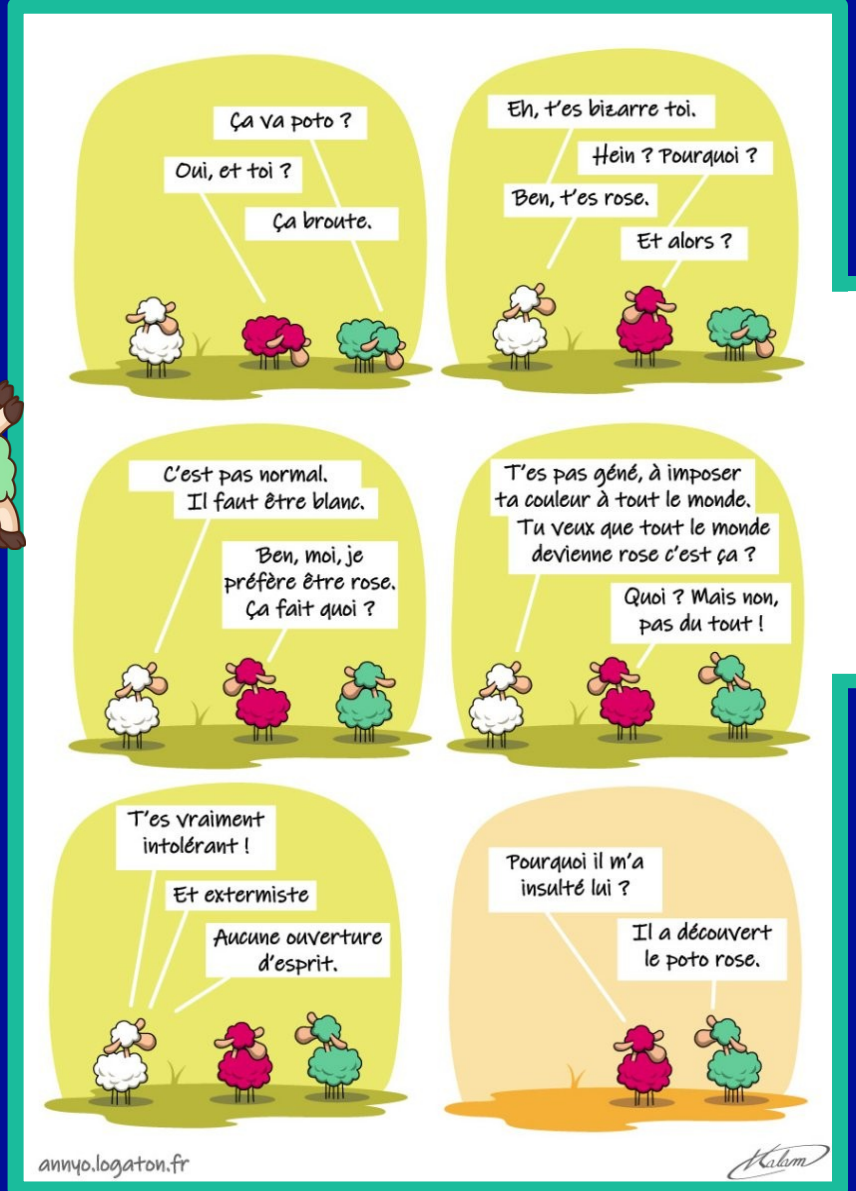

(Bonus)

Code & Slides

https://github.com/benoitmasson/gi-go

OVHcloud